

Clase 5a - Introducción al uso y aplicación de paquetes estadísticos para el tratamiento de fuentes de información en investigación social cuantitativa

José Rodríguez de la Fuente - Albano Vergara Parra

Table of contents

Transformando los datos: creación y modificación variables	1
Creación de variables mediante cálculos y expresiones condicionales	2
Recodificación de variables	4

En esta clase vamos a trabajar con la base de la *Encuesta de Consumos Culturales* de 2022-2023 realizada por el Ministerio de Cultura. También activaremos la librería **Tidyverse**.

Agregaremos la opción `na = "Ns/Nc"` para que los valores de “No sabe/No contesta” se interpreten como valores perdidos. Esto es importante porque, si no lo hacemos, esos valores serán interpretados como caracteres y no como valores perdidos, lo que podría afectar nuestros análisis posteriores.

```
library(tidyverse)

consumos_culturales <-
  read_csv("https://datos.cultura.gob.ar/dataset/251c2ac2-e670-451c-9dbf-a4212af225b5/resor
  na = "Ns/Nc")
```

Transformando los datos: creación y modificación variables

Teniendo ya la base en formato ordenado, habiendo seleccionado aquellas variables que vayamos a utilizar y filtrando los casos que nos interesan, el siguiente paso en el trabajo cuantitativo suele ser la creación de nuevas variables y/o la modificación de las existentes.

Esta fase en el trabajo investigativo puede implicar, entre otras opciones:

- Generar nuevas variables a partir de las existentes. Por ejemplo, realizar una sumatoria o resta aritmética a partir de los datos disponibles en dos o más variables.
- Recodificar una variable existente. Por ejemplo, reduciendo el número de categorías de una variable categórica o numérica (grupos etarios, niveles de ingreso, etc.).
- Generar una nueva variable a partir del cumplimiento de determinadas condiciones combinadas. Generalmente este trabajo se realiza para construir variables complejas. Por ejemplo, crear una variable que indique el tipo de hogar en cada caso.

Creación de variables mediante cálculos y expresiones condicionales

Para realizar estas operaciones utilizaremos siempre la función `mutate()` del paquete `dplyr`. Básicamente esta función nos creará una nueva columna en la matriz de datos, que contendrá los valores que le indiquemos. Por ejemplo, vamos a crear una variable que mida la proporción de películas nacionales vistas en el cine sobre el total de películas vistas en el cine.

Para construir dicho indicador, primero vamos a identificar aquellas variables que necesitamos, es decir, el número de asistencias al cine `cine4` y la cantidad de veces que asistió a ver películas nacionales `cine5`. Entonces, en primer lugar, vamos a crear una nueva variable llamada `cine_nacional` que represente el cociente entre ambas variables.

Manual de códigos

Recuerden siempre tener *a mano* el manual de códigos o el diseño de registro de la encuesta que están utilizando para saber el nombre de las variables sobre las que se realizarán las operaciones. En este caso usaremos directamente el [cuestionario de la encuesta](#).

```
consumos_culturales <- consumos_culturales %>%  
  mutate(cine_nacional = cine5 / cine4)
```

Ya contamos con la variable `cine_nacional` que nos indica la proporción de películas nacionales vistas en el cine. A continuación, podemos armar una nueva variable que identifique a aquellas personas que puedan declararse como *cinéfilas nacionales* cuando la proporción de películas nacionales vistas en el cine sea mayor o igual a 0.5.

Para ello, introduciremos una nueva función que nos permite plantear condiciones: `case_when()`. Esta función es muy similar al IF en SPSS o la función `ifelse()` de R base. `case_when()` se pasa dentro del `mutate`, y se le indica la condición que se quiere evaluar y el valor que se le asignará a la nueva variable en caso de que se cumpla dicha condición, separado por el símbolo `~`. Cada argumento se separa por una coma.

```
consumos_culturales <- consumos_culturales %>%
  mutate(cinefila_nac = case_when(cine_nacional >= 0.5 ~ 1,
                                   cine_nacional < 0.5 ~ 0))
```

Este cálculo podría resumirse aún más, concatenando ambas operaciones dentro de la función `mutate()`.

```
consumos_culturales <- consumos_culturales %>%
  mutate(cine_nacional = cine5 / cine4,
         cinefila_nac = case_when(cine_nacional >= 0.5 ~ 1,
                                   cine_nacional < 0.5 ~ 0))
```

Si queremos observar los resultados de la tarea realizada, podemos hacerlo a través de la función `table()`.

```
table(consumos_culturales$cinefila_nac)
```

```
0    1
912 215
```

```
table(consumos_culturales$cinefila_nac, useNA = "always") # Agrega los casos
↪ NAs
```

```
0    1 <NA>
912 215 2253
```

Por último, debido a que es una variable categórica, podemos convertirla en factor con la función `factor()` como lo vimos anteriormente. Vamos a indicar que el valor 0 se denomine “No ve cine nacional” y el valor 1 “Ve cine nacional”.

```
consumos_culturales <- consumos_culturales %>%
  mutate(cinefila_nac = factor(cinefila_nac,
                                labels = c("No ve cine nacional", "Ve cine
↪ nacional")))
table(consumos_culturales$cinefila_nac, useNA = "always")
```

```
No ve cine nacional    Ve cine nacional    <NA>
                912                215                2253
```

Recodificación de variables

El combo `mutate()` y `case_when()` también nos permite recodificar variables, es decir, cambiar los valores de una variable por otros o reducir su número de categorías. Es una práctica frecuente en el análisis de datos, ya que permite simplificar, posteriormente, la interpretación de los resultados.

Por ejemplo, siguiendo con la encuesta de consumos culturales podemos recodificar la variable *libro5* que mide la cantidad de libros que las personas han leído en el último año. La nueva variable puede tener 4 categorías:

- No lector
- Lector ocasional: 1 a 3 libros leídos
- Lector frecuente: 4 a 10 libros leídos
- Lector ávido: más de 10 libros leídos

```
consumos_culturales <- consumos_culturales %>%  
  mutate(tipo_lector = case_when(is.na(libro5) ~ "No lector",  
                                libro5 >= 1 & libro5 <= 3 ~ "Lector ocasional",  
                                libro5 >= 4 & libro5 <= 10 ~ "Lector frecuente",  
                                libro5 > 10 ~ "Lector ávido"))
```

Fijense que para la primera categoría hemos utilizado la función `is.na()` para identificar los casos perdidos. Esto es importante para que esos casos no sean tratados como *NAs* en la nueva variable.

Otra forma de indicar que queremos agrupar valores que se encuentran en un rango es través del operador de pertenencia `%in%` que evalúa si los elementos de un vector están presentes en otro vector. Por ejemplo, podemos crear la misma variable del siguiente modo:

```
consumos_culturales <- consumos_culturales %>%  
  mutate(tipo_lector = case_when(is.na(libro5) ~ "No lector",  
                                libro5 %in% c(1:3) ~ "Lector ocasional",  
                                libro5 %in% c(4:10) ~ "Lector frecuente",  
                                libro5 > 10 ~ "Lector ávido"))
```

💡 Atención

El operador `%in%` también puede ser utilizado para identificar valores en un vector alfanumérico o de cadena. En ese caso debemos ingresar los valores a evaluar dentro de la función `c()`. Por ejemplo, provincia `%in% c("Buenos Aires", "Chaco", "Formosa")`.